

Modélisation de réseaux neuronaux par processus de Hawkes

Inférence, sélection de neurones et estimation d'un modèle de diffusion

Victor Schmit

CentraleSupélec

May 21, 2026

1 Introduction

2 Données

- Description
- Prétraitement

3 Modélisation

- Processus de Hawkes
- Approche de résolution

4 Détermination du sous-réseau

5 Estimation du processus

6 Résultats

Outline

1 Introduction

2 Données

- Description
- Prétraitement

3 Modélisation

- Processus de Hawkes
- Approche de résolution

4 Détermination du sous-réseau

5 Estimation du processus


6 Résultats

Objectif

- Comprendre les interactions dans un réseau neuronal
- Identifier un sous-réseau pertinent
- Modéliser la dynamique du neurone cible

Approche :

- Processus de Hawkes multivarié
- Estimation d'un modèle de diffusion (jump-diffusion)



Outline

1 Introduction

2 Données

- Description
- Prétraitement

3 Modélisation

- Processus de Hawkes
- Approche de résolution

4 Détermination du sous-réseau

5 Estimation du processus



6 Résultats

Types de données

- Données intracellulaires :
 - Mesure continue du potentiel de membrane d'un neurone cible
- Données extracellulaires :
 - Trains de spikes de 250 neurones
 - Représentent l'activité du réseau neuronal environnant

Contexte expérimental :

- Préparation biologique (tortue)
- 10 enregistrements (40s) via électrodes
- Détection des spikes à partir du signal extracellulaire





Détection des spikes

- Détection via seuil sur le potentiel (-20mV)
- Comparaison avec les spikes extracellulaires

Nettoyage :

- Sélection d'une bonne fenêtre temporelle (garder la même distribution dans le temps)
- Suppression des neurones silencieux
- Suppression des essais sans spikes pour le neurone centrale



Outline

1 Introduction

2 Données

- Description
- Prétraitement

3 Modélisation

- Processus de Hawkes
- Approche de résolution

4 Détermination du sous-réseau

5 Estimation du processus

6 Résultats

Modèle global

Modèle

$$dX_t = b(X_t) dt + \sigma(X_t) dW_t + a(X_{t-}) \sum_j dN_t^j$$

- X_t : potentiel de membrane
- $b(X_t)$: dérive (dynamique intrinsèque)
- $\sigma(X_t)$: diffusion (bruit)
- $a(X_t)$: impact des spikes
- N_t^j : processus de comptage (activité réseau)

Hypothèse clé

Le processus de Hawkes (réseau) est **indépendant** du potentiel de membrane X_t .

Processus de comptage

Processus ponctuel

Un processus ponctuel est une variable aléatoire $N : \Omega \rightarrow \mathcal{N}(X)$, où X est un espace ambiant et où $\mathcal{N}(X)$ désigne les parties dénombrables de X .

- X : espace ambiant (ici $X = \mathbb{R}_+$)
- $\mathcal{N}(X)$: ensemble des sous-ensembles dénombrables de X
- Une réalisation correspond à une suite de temps de saut : $(T_n)_{n \geq 1}$

Processus de comptage associé

$$N_t = \sum_{n \geq 1} \mathbf{1}_{\{T_n \leq t\}}$$

- N_t compte le nombre d'événements avant t
- Dans notre cas : événements = spikes neuronaux

Intensité d'un processus de comptage

Intensité conditionnelle

On dit que $(\lambda_t)_{t \geq 0}$ est l'intensité prédictible de N si

$$M_t := N_t - \int_0^t \lambda_s ds$$

est une martingale relativement à la filtration naturelle.

Interprétation infinitésimale (heuristique)

Pour $h \rightarrow 0$,

$$\mathbb{P}(N_{t+h} - N_t = 1 \mid \mathcal{F}_t) = \lambda_t h + o(h),$$

- λ_t décrit donc le taux instantané d'apparition d'un événement conditionnellement au passé.

Processus de Hawkes

Définition

Un processus de Hawkes multivarié $(N_j(t))_{1 \leq j \leq M}$ est un processus de comptage dont l'intensité conditionnelle vérifie :

$$\lambda_j(t) = \mu_j + \sum_{k=1}^M \int_0^t \phi_{jk}(t-s) dN_k(s)$$

- $\mu_j \geq 0$: intensité de base
- $\phi_{jk}(t) = a_{jk} \cdot \beta_j \exp(-\beta_j t)$: fonction d'interaction (kernel)

Interprétation

- auto-excitation ($j = k$)
- interaction entre neurones ($j \neq k$)

Algorithme de thinning

Problème

Simuler un processus de Hawkes avec une intensité $\lambda(t)$ dépendant du temps et de l'histoire.

Principe

- Simuler un processus de Poisson homogène de taux $\bar{\lambda}$
- Pour chaque événement candidat à l'instant t :


accepter avec probabilité $\frac{\lambda(t)}{\bar{\lambda}}$

Ce que permet le thinning

- Simuler des processus à intensité variable
- Conserver la bonne loi du processus cible

Algorithme de thinning

- Simuler des processus à intensité variable
- Conserver la bonne loi du processus cible



Approche de résolution

Étape 1 : Identification du réseau

- Estimation d'un processus de Hawkes à partir des spikes extracellulaires
- Construction d'une matrice d'adjacence
- Sélection des neurones influents sur le neurone cible

Étape 2 : Estimation du modèle de diffusion à sauts

- Construction du processus de comptage N_t
- Estimation non paramétrique de :
 - $b(x)$: dérive
 - $\sigma(x)$: diffusion
 - $a(x)$: amplitude des sauts
- Ajustement du modèle $dX_t = b(X_t)dt + \sigma(X_t)dW_t + a(X_t)dN_t$

Outline

1 Introduction

2 Données

- Description
- Prétraitement

3 Modélisation

- Processus de Hawkes
- Approche de résolution

4 Détermination du sous-réseau

5 Estimation du processus

6 Résultats



Estimation ADM4

Principe

Estimer les paramètres du processus de Hawkes en maximisant une vraisemblance pénalisée :


$$\max_{\mu, A} \mathcal{L}(\mu, A) - \lambda_1 \|A\|_1$$

- $\mathcal{L}$: log-vraisemblance du modèle de Hawkes
- $\|A\|_1$: pénalisation de parcimonie (sélection de neurones)



Matrices réduites

- 22 neurones sélectionnés parmi 250
- β fixé à 20 Hz (decay rate)



Outline

1 Introduction

2 Données

- Description
- Prétraitement

3 Modélisation

- Processus de Hawkes
- Approche de résolution

4 Détermination du sous-réseau

5 Estimation du processus

6 Résultats

Modèle à estimer

Modèle de diffusion à sauts

$$dX_t = b(X_t) dt + \sigma(X_t) dW_t + a(X_{t-}) \sum_{j=1}^M dN_t^j$$

- X_t : potentiel de membrane
- (N_t^j) : processus de Hawkes (réseau neuronal)

Objectif

Estimer non paramétriquement :

$$b(x), \quad \sigma^2(x), \quad a(x)$$

Difficulté

Présence de sauts (spikes)

Décomposition du problème

Idée clé

On introduit la fonction :

$$g(x) = \sigma^2(x) + a^2(x) f(x)$$

- $f(x) = \mathbb{E}[\lambda_t \mid X_t = x]$
- λ_t : intensité du processus de Hawkes

Stratégie

- 1 Estimer $\sigma^2(x)$
- 2 Estimer $g(x)$
- 3 En déduire :

$$a^2(x) = \frac{g(x) - \sigma^2(x)}{f(x)}$$

Discrétisation et variables observées

Incréments

$$Y_{k\Delta} = \frac{X_{(k+1)\Delta} - X_{k\Delta}}{\Delta}$$
$$Z_{k\Delta} = \frac{(X_{(k+1)\Delta} - X_{k\Delta})^2}{\Delta}$$

- $Y \rightarrow$ information sur la dérive
- $Z \rightarrow$ information sur la variance

Problème

Les sauts biaisent fortement ces quantités

Troncature des sauts

Fonction de troncature

$$\varphi(x) = \begin{cases} 1 & |x| < 1 \\ e^{\frac{1}{3} + \frac{1}{x^2 - 4}} & 1 \leq |x| < 2 \\ 0 & |x| \geq 2 \end{cases}$$

- Permet de filtrer les gros incréments (sauts)
- Stabilise l'estimation de σ^2

Variable tronquée

$$Z_{k\Delta}^\varphi = Z_{k\Delta} \cdot \varphi\left(\frac{\Delta X}{\Delta^\beta}\right)$$

Projection sur un espace de fonctions

Approximation

On cherche :

$$t(x) \in S_m = \text{span}(\varphi_1, \dots, \varphi_{D_m})$$

- S_m : espace de dimension D_m
- Base (Fourier ou splines)

Exemple

$$t(x) = \sum_{k=1}^{D_m} \alpha_k \varphi_k(x)$$

- Permet une estimation non paramétrique

Estimation des fonctions

Exemple pour g

$$\hat{g}_m = \arg \min_{t \in S_m} \left(\frac{1}{n} \sum (Y_{k\Delta} - t(X_{k\Delta}))^2 + \text{pen}(m) \right)$$

Exemple pour σ^2

$$\hat{\sigma}_m^2 = \arg \min_{t \in S_m} \left(\frac{1}{n} \sum (Z_{k\Delta}^\varphi - t(X_{k\Delta}))^2 + \text{pen}(m) \right)$$

Choix du modèle (pénalisation)

Principe

Éviter le sur-apprentissage

Critère pénalisé

$$\text{crit}(m) = \text{erreur} + \text{pen}(m)$$

- $\text{pen}(m) \propto \frac{D_m}{n}$ ou $\frac{D_m}{n\Delta}$
- dépend de la fonction estimée

Choix final

$$\hat{m} = \arg \min_m \text{crit}(m)$$

Reconstruction des paramètres

Étapes finales

- Estimation de λ (Hawkes)
- Estimation de $\sigma^2(x)$
- Estimation de $g(x)$

Formule finale

$$\hat{a}^2(x) = \frac{\hat{g}(x) - \hat{\sigma}^2(x)}{\hat{f}(x)}$$

Puis

$\hat{b}(x)$ estimé par régression sur Y

Outline

1 Introduction

2 Données

- Description
- Prétraitement

3 Modélisation

- Processus de Hawkes
- Approche de résolution

4 Détermination du sous-réseau

5 Estimation du processus

6 Résultats





Résultats : comparaison des deux projections

- **Projection trigonométrique** : base cosinus/sinus
- **Projection spline** : base spline avec contrainte de positivité
- Comparaison sur les estimations de :





$$g(x), \quad \sigma^2(x), \quad a(x), \quad b(x)$$

ainsi que sur la trajectoire reconstruite.



Projection cosinus : estimation des coefficients



Projection spline : estimation des coefficients



Comparaison des trajectoires reconstruites



Analyse des résultats

Constat

Les deux approches permettent de reconstruire les coefficients du modèle ainsi qu'une trajectoire simulée du potentiel membranaire.

- La **projection cosinus** fournit une estimation flexible, mais peut produire des oscillations et des valeurs localement non physiques.
- La **projection spline** donne des courbes plus régulières.
- Elle est particulièrement adaptée pour imposer des contraintes de positivité sur

$$a(x) \quad \text{et} \quad \sigma(x).$$

- La comparaison des trajectoires observée/simulée permet d'évaluer la qualité globale de l'ajustement.

Conclusion sur la comparaison

Conclusion

La base spline est plus adaptée lorsque l'on veut :

- préserver la régularité des estimateurs,
- imposer la positivité de certains paramètres,
- obtenir une interprétation plus stable du modèle.

À retenir

La projection cosinus constitue une bonne référence, mais la projection spline semble mieux répondre aux contraintes structurelles du modèle.

Références I



Chiara Amorino, Charlotte Dion, Arnaud Gloter, and Sarah Lemler.

On the nonparametric inference of coefficients of self-exciting jump-diffusion, April 2022.

[arXiv:2011.12387 \[math.ST\]](#).



Anna Bonnet, Charlotte Dion, François Gindraud, and Sarah Lemler.

Neuronal Network Inference and Membrane Potential Model using Multivariate Hawkes Processes, August 2021.

[arXiv:2108.00758 \[math.ST\]](#).



Y. Chen.

Thinning Algorithms for Simulating Point Processes.
2016.



Charlotte Dion and Sarah Lemler.

Nonparametric drift estimation for diffusions with jumps driven by a Hawkes process, November 2019.

[arXiv:1904.08232 \[math.ST\]](#).

Références II



Sarah Lemler.

Processus de comptage.

Cours/TD, 3ème année d'école, niveau M2, ENSAE, ENSIIE, Université d'Évry Val d'Essonne et École CentraleSupélec, 2017–2019.

Support de cours.



Ke Zhou, Hongyuan Zha, and Le Song.

Learning Triggering Kernels for Multi-dimensional Hawkes Processes.

In *Proceedings of the 30th International Conference on Machine Learning*, pages 1301–1309.

PMLR, May 2013.

ISSN: 1938-7228.